### 10 Estimarea parametrilor: intervale de încredere

Intervalele de încredere pentru un parametru necunoscut  $\theta$  al unei distribuții (spre exemplu pentru media unei populații) sunt intervale ( $\theta_1, \theta_2$ ) ce conțin parametrul  $\theta$ , nu cu certitudine, si cu anumită probabilitate  $\gamma$  (spre exemplu cu probabilitate  $\gamma = 95\%$  sau  $\gamma = 99\%$ ). Valoarea lui  $\gamma$  se numește **nivel de încredere/nivel de semnificație** iar  $\theta_1$  și  $\theta_2$  se numesc limita de încredere inferioară și superioară.

Un astfel de interval  $(\theta_1, \theta_2)$  este calculat folosind o selecție din populație. Valoarea  $\gamma = 95\%$  înseamnă că probabilitatea ca intervalul  $(\theta_1, \theta_2)$  să nu-l conțină pe  $\theta$  este  $1 - \gamma = 5\% = 0.05$ , adică aproximativ unul din 20 de intervale astfel determinate nu îl va conține pe  $\theta$ . Cu cât valoarea lui  $\gamma$  este mai apropiată de 1, cu atât este mai mică probabilitatea erorii  $1 - \gamma$  ca intervalul de încredere să nu-l conțină parametrul  $\theta$ , dar în același timp lungimea  $\theta_2 - \theta_1$  a intervalului de încredere devine mai mare (tinde la infinit pentru  $\gamma \to 1$ ).

Intervalele de încredere sunt mai utile decît estimatorii punctuali ai parametrilor necunoscuți, deoarece având intervalul de încredere putem considera ca estimator mijlocul  $\frac{\theta_1+\theta_2}{2}$  al intervalului (în acest caz, probabilitatea ca  $\theta$  să difere față de estimatorul considerat cu mai puțin de  $\frac{\theta_2-\theta_1}{2}$  este egală cu  $\gamma$ ).

Pentru a determina capetele  $\theta_1$  și  $\theta_2$  ale intervalului de încredere, considerăm un eșantion  $x_1, \ldots, x_n$  din populația dată. Aceste valori sunt valorile observate ale unei variabile aleatoare X (reprezentând populația studiată), dar ele pot fi privite ca valori ale n variabile aleatoare independente  $X_1, \ldots, X_n$  având aceeași distribuție cu variabila aleatoare X

Atunci  $\theta_1 = \theta_1(x_1, \dots, x_n)$  și  $\theta_2 = \theta_2(x_1, \dots, x_n)$  sunt valorile observate ale variabilelor aleatoare  $\Theta_1 = \Theta_1(X_1, \dots, X_n)$  și  $\Theta_2 = \Theta_2(X_1, \dots, X_n)$ . Condiția ca intervalul  $(\theta_1, \theta_2)$  să-l conțină parametrul  $\theta$  cu probabilitate  $\gamma$  se poate scrie deci sub forma

$$P\left(\Theta_1 < \theta < \Theta_2\right) = \gamma. \tag{57}$$

Pentru a determina variabilele aleatoare  $\Theta_1$  și  $\Theta_2$  folosim următoarea.

Teorema 10.1 (Suma de variabile aleatoare normale independente) Fie  $X_1, \ldots, X_n$  variabile aleatoare normale independente, având fiecare medie  $\mu$  şi dispersie  $\sigma^2$ . Atunci au loc următoarele.

- a) Suma  $X_1 + \ldots + X_n$  este o variabilă aleatoare normală cu medie  $n\mu$  și dispersie  $n\sigma^2$ .
- **b)** Variabila aleatoare

$$\overline{X} = \frac{X_1 + \ldots + X_n}{n} \tag{58}$$

este o variabilă aleatoare normală cu medie  $\mu$  și dispersie  $\sigma^2/n$ .

c) Variabila aleatoare

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{p}}} \tag{59}$$

este o variabilă aleatoare normală standard (cu medie 0 și dispersie 1).

**Demonstrație.** a) Este suficient să demonstrăm afirmația din enunț în cazul n=2 (demonstrația poate fi apoi completată prin inducție matematică).

Se poate arăta că deoarece variabilele aleatoare normale  $X_1$  şi  $X_2$  sunt independente, variabila aleatoare  $X_1 + X_2$  este de asemenea o variabilă aleatoare normală.

Avem

$$M(X_1 + X_2) = M(X_1) + M(X_2) = \mu + \mu = 2\mu,$$

și deci variabila aleatoare  $X_1 + X_2$  are medie  $2\mu$ .

De asemenea, deoarece variabilele aleatoare  $X_1$  şi  $X_2$  sunt independente, se poate arăta că dispersia sumei  $X_1 + X_2$  este egală cu suma dispersiilor variabilelor aleatoare  $X_1$  şi  $X_2$ , adică

$$\sigma^{2}(X_{1} + X_{2}) = \sigma^{2}(X_{1}) + \sigma^{2}(X_{2}) = \sigma^{2} + \sigma^{2} = 2\sigma^{2},$$

și deci variabila aleatoare  $X_1 + X_2$  are dispersie  $2\sigma^2$ .

Am arătat deci că  $X_1 + X_2 \in \mathcal{N}(2\mu, 2\sigma^2)$ , încheiând astfel prima parte a demonstrației.

b) Conform primei părți a demonstrație avem că  $X_1 + \ldots + X_n \in \mathcal{N}\left(n\mu, n\sigma^2\right)$  este o variabilă aleatoare normală cu medie  $n\mu$  și dispersie  $n\sigma^2$ . Folosind Teorema 4.4 rezultă că variabila aleatoare  $\overline{X} = \frac{X_1 + \ldots + X_n}{n} \in \mathcal{N}\left(\frac{n\mu}{n}, \frac{n\sigma^2}{n^2}\right) = \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$  este o variabilă aleatoare normală cu medie  $\mu$  și dispersie  $\frac{\sigma^2}{n}$ .

c) Cum  $\overline{X} \in \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$ , folosind din nou Teorema 4.4 obținem că variabila aleatoare standardizată  $Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \in \mathcal{N}\left(0, 1\right)$  este o variabilă aleatoare normală cu medie 0 și dispersie 1.

Folosind teorema anterioară, putem acum determina intervale de încredere pentru media și dispersia unei populații normale după cum urmează.

## 10.1 Intervale de încredere pentru media $\mu$ unei populații normale cu dispersie $\sigma^2$ cunoscută

Dacă populația  $X \in \mathcal{N}(\mu, \sigma^2)$  este normală cu medie  $\mu$  (necunoscută) și dispersie  $\sigma^2$  (cunoscută), conform Teoremei 10.1 rezultă că variabila aleatoare

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \in \mathcal{N}(0, 1)$$

este o variabilă aleatoare normală standard.

Pentru un nivel de încredere  $\gamma$  fixat, folosind Anexa 2 determinăm valoarea constantei c astfel încât

$$\gamma = P\left(-c \le Z \le c\right) = \Phi\left(c\right) - \Phi\left(-c\right).$$

Relația anterioară se poate scrie sub forma

$$P\left(-c \le \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \le c\right) = \gamma,$$

sau echivalent (rezolvând dubla inegalitate în raport cu  $\mu$ )

$$P\left(\overline{X} - c\frac{\sigma}{\sqrt{n}} \le \mu \le \overline{X} + c\frac{\sigma}{\sqrt{n}}\right) = \gamma.$$

Considerând  $\Theta_1 = \overline{X} - c \frac{\sigma}{\sqrt{n}}$  şi  $\Theta_2 = \overline{X} + c \frac{\sigma}{\sqrt{n}}$ , relația anterioară se poate scrie echivalent sub forma

$$P\left(\Theta_1 \le \mu \le \Theta_2\right) = \gamma.$$

Înlocuind variabilele aleatoare  $X_1, \ldots, X_n$  prin valorile observate  $x_1, \ldots, x_n$  ale eşantionului obținem că un interval de încredere pentru media necunoscută  $\mu$  a populației este

$$(\theta_1, \theta_2) = \left(\overline{x} - c\frac{\sigma}{\sqrt{n}}, \overline{x} + c\frac{\sigma}{\sqrt{n}}\right) \tag{60}$$

Exemplul 10.2 Să se determine un interval de 95% încredere pentru media necunoscută  $\mu$  a unei populații normale cu dispersie cunoscută  $\sigma^2 = 9$ , folosind un eșantion de volum n = 100 cu medie  $\overline{x} = 5$ .

Folosind Anexa 2 determinăm valoarea c corespunzătoare probabilității  $\gamma = 0.95$  astfel încât

$$\Phi(c) - \Phi(-c) = \gamma = 0.95,$$

 $\sin abtinem c = 1.960.$ 

Folosind formula (60) determinăm intervalul de încredere pentru media necunoscută μ a populației

$$(\theta_1, \theta_2) = \left(\overline{x} - c\frac{\sigma}{\sqrt{n}}, \overline{x} + c\frac{\sigma}{\sqrt{n}}\right) = (\theta_1, \theta_2) = \left(5 - 1.960\frac{3}{\sqrt{100}}, 5 + 1.960\frac{3}{\sqrt{100}}\right) = (4.412, 5.588).$$

O altă problemă în determinarea unui interval de încredere este legată de alegerea volumului selecției, ca în exemplul următor.

**Exemplul 10.3** Cât de mare trebuie ales volumul n al selecției în exemplu anterior dacă se dorește obținerea unui interval de 95% încredere de lungime cel mult L = 0.4?

Intervalul de încredere pentru media  $\mu$  a populației din formula (60) are lungimea

$$\theta_2 - \theta_1 = \left(\overline{x} + c\frac{\sigma}{\sqrt{n}}\right) - \left(\overline{x} - c\frac{\sigma}{\sqrt{n}}\right) = 2c\frac{\sigma}{\sqrt{n}}.$$

Egalând această expresie cu valoarea L dorită, obținem

$$L = 2c \frac{\sigma}{\sqrt{n}},$$

de unde rezolvând în raport cu n se obține

$$n = \left(\frac{2c\sigma}{L}\right)^2 = \left(\frac{2 \cdot 1.960 \cdot 3}{0.4}\right)^2 = 864.36.$$

Pentru a obține intervalul de încredere dorit, trebuie să alegem un volum de selecție n=865.

Observația 10.4 Se poate arăta că pentru un nivel de încredere  $\gamma \to 1$ , lungimea intervalului de încredere corespunzător tinde câtre infinit  $\theta_2 - \theta_1 \to \infty$ .

# 10.2 Intervale de încredere pentru media $\mu$ unei populații normale cu dispersie $\sigma^2$ necunoscută

În cazul în care dispersia  $\sigma^2$  a populației este necunoscută, nu mai putem utiliza formula (60) pentru a determina un interval de încredere pentru media necunoscută  $\mu$  a populației.

Deoarece valoarea abaterii pătratice medii  $\sigma$  din această formulă este necunoscută, înlocuim pe  $\sigma$  prin estimatorul

$$s = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \overline{x})^2}{n-1}}$$
 (61)

al lui  $\sigma$ .

Fâcând însă această înlocuire, variabila aleatoare corespunzătoare

$$Z = \frac{\overline{X} - \mu}{\frac{s}{\sqrt{n}}}$$

nu mai este o variabilă aleatoare normală (este o variabilă aleatoare T/Student cu n-1 grade de libertate, având funcția de distribuție F(x) tabelată în Anexa 3), și deci valoarea c trebuie determinată folosind acest tabel astfel încât

$$F(c) - F(-c) = \gamma.$$

Ca și în cazul distribuției normale standard, distribuția Student are o funcție de densitate simetrică față de origine, și deciF(-x) = 1 - F(x) pentru orice  $x \in \mathbb{R}$ . Înlocuind în relația ant6erioară F(-c) prin 1 - F(c) obținem echivalent

$$F(c) - (1 - F(c)) = \gamma$$

sau

$$F\left(c\right) = \frac{1+\gamma}{2}.\tag{62}$$

Obținem deci că în cazul unei populații având dispersie necunoscută  $\sigma^2$ , pentru un nivel de încredere  $\gamma$  fixat, intervalul de încredere pentru media necunoscută  $\mu$  a populației este

$$(\theta_1, \theta_2) = \left(\overline{x} - c\frac{s}{\sqrt{n}}, \overline{x} + c\frac{s}{\sqrt{n}}\right) \tag{63}$$

unde n este volumul selecției,  $\overline{x} = \frac{x_1 + \ldots + x_n}{n}$  este media eșantionului, estimatorul s al abaterii pătratice medii  $\sigma$  este dat de formula (61), iar c este determinat din Anexa 3 astfel conform relației (62) pentru n-1 grade de libertate.

Exemplul 10.5 Cinci măsurători pentru temperatura de aprindere a motorinei (în grade Fahrenheit) sunt

Presupunând că temperatura de aprindere a motorinei este o variabilă aleatoare normală, să se determine un interval de 99% încredere pentru temperatura medie  $\mu$  de aprindere a motorinei.

În acest caz, deoarece dispersia  $\sigma^2$  este necunoscută, pentru a determina intervalul de încredere vom folosi formula (63).

Folosind datele din eșantion determinăm media de selecție

$$\overline{x} = \frac{x_1 + x_2 + x_3 + x_4 + x_5}{5} = 144.6$$

$$s = \sqrt{\frac{\sum_{i=1}^{5} (x_i - \overline{x})^2}{5 - 1}} = \sqrt{3.8} = 1.95.$$

Folosind Anexa 3 pentru a determina valoarea lui c astfel încât să aibă loc relația (62), adică  $F(c) = \frac{1+0.99}{2} = 0.995$  (alegem n-1=5-1=4 grade de libertate), și obținem c=4.60.

Înlocuind aceste valori în formula (63), obținem că un interval de 99% pentru temperatura medie de aprindere a motorinei este

$$(\theta_1, \theta_2) = \left(\overline{x} - c\frac{s}{\sqrt{n}}, \overline{x} + c\frac{s}{\sqrt{n}}\right) = \left(144.6 - 4.60\frac{1.95}{\sqrt{5}}, 144.6 + 4.60\frac{1.95}{\sqrt{5}}\right) = (140.5, 148.7).$$

#### 10.3 Intervale de încredere pentru dispersia $\sigma^2$ unei populații normale

Procedând similar Teoremei 10.1, și folosind în acest caz estimatorul

$$S^{2} = \frac{1}{n-1} \sum_{i=1}^{n} (X_{i} - \overline{X})^{2}$$

al dispersiei, se poate arăta că variabila aleatoare

$$Y = (n-1)\frac{S^2}{\sigma^2}$$

are o distribuție  $\chi^2$  cu n-1 grade de libertate (valorile funcției de distribuție sunt tabelate în Anexa 4).

Deoarece această distribuție nu este simetrică (ca în cazul distribuției normale), în loc de -c și c determinăm două constante  $c_1$  și  $c_2$  astfel încât  $S^2$  se află între  $c_1$  și  $c_2$  cu probabilitate  $\gamma$ , adică

$$P\left(c_1 \le Y \le c_2\right) = \gamma. \tag{64}$$

Spre exemplu, determinăm constantele  $c_1$  și  $c_2$  astfel încât

$$F(c_1) = \frac{1-\gamma}{2} \qquad \text{si} \qquad F(c_2) = \frac{1+\gamma}{2}, \tag{65}$$

unde F(x) este în acest caz funcția de distribuție a variabilei aleatoare  $\chi^2$  cu n-1 grade de libertate din Anexa 4 (procedând astfel, aria de sub densitatea variabilei aleatoare  $\chi^2$  cuprinsă între  $c_1$  și  $c_2$  va fi egală cu  $\frac{1+\gamma}{2} - \frac{1-\gamma}{2} = \gamma$ , și are deci loc relația (64) de mai sus).

Relația (64) se mai poate scrie echivalent sub forma

$$P\left(c_1 \le (n-1)\frac{S^2}{\sigma^2} \le c_2\right) = \gamma,$$

de unde rezolvând inegalitățile în raport cu  $\sigma^2$  obținem

$$P\left(\frac{n-1}{c_2}S^2 \le \sigma^2 \le \frac{n-1}{c_1}S^2\right) = \gamma,$$

sau

$$P(\Theta_1 \le \mu \le \Theta_2) = \gamma$$
,

unde 
$$\Theta_1 = \frac{n-1}{c_2} S^2$$
 și  $\Theta_2 = \frac{n-1}{c_1} S^2$ .

Înlocuind variabilele aleatoare  $X_1, \ldots, X_n$  prin valorile observate  $x_1, \ldots, x_n$  ale eşantionului obținem că un interval de încredere pentru dispersia necunoscută  $\sigma^2$  a populației este

$$(\theta_1, \theta_2) = \left(\frac{n-1}{c_2}s^2, \frac{n-1}{c_1}s^2\right),\tag{66}$$

unde n este volumul selecției,  $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \overline{x})^2$  este estimatorul dispersiei  $\sigma^2$ , iar  $c_{1,2}$  sunt determinate din Anexa 4 pentru n-1 grade de libertate conform relațiilor (65).

Exemplul 10.6 Să se determine un interval de 95% încredere pentru dispersia necunoscută  $\sigma^2$  a eșantionului

reprezentând rezistența la rupere (kg/mm² a unei table de metal).

Folosind valorile eşantionului (n = 14 valori) determinăm media selecției  $\overline{x} = \frac{x_1 + ... + x_{14}}{14} = 87.28$  și estimatorul  $s^2$  al dispersiei

$$s^2 = \frac{1}{14 - 1} \sum_{i=1}^{14} (x_i - \overline{x}) = 25.15.$$

Folosind Anexa 4 (cu n - 1 = 14 - 1 = 13 grade de libertate), determinăm constantele  $c_{1,2}$  astfel încât  $F(c_1) = \frac{1-\gamma}{2} = 0.025$  și  $F(c_2) = \frac{1+\gamma}{2} = 0.975$ . Obținem  $c_1 = 5.01$  și  $c_2 = 24.74$ .

Folosind formula (66) determinăm intervalul de încredere pentru dispersia necunoscută  $\sigma^2$ 

$$(\theta_1,\theta_2) = \left(\frac{n-1}{c_2}s^2, \frac{n-1}{c_1}s^2\right) = \left(\frac{14-1}{24.74}25.15, \frac{14-1}{5.01}25.15\right) = (13.21,65.25).$$

#### 10.4 Intervale de încredere pentru alte distribuții

Intervalele de încredere pentru media  $\mu$  și dispersia  $\sigma^2$  determinate în secțiunile anterioare se aplică în cazul unei distribuții normale.

Pentru a obține aceste formule s-a folosit faptul că dacă  $X_1, \ldots, X_n$  sunt variabile aleatoare normale independente cu medie  $\mu$  și dispersie  $\sigma^2$ , atunci variabila aleatoare

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

este o variabilă aleatoare normală standard.

Una din teoremele fundamentale ale Teoriei probabilităților (Teorema Limită centrală) afirmă că dacă  $X_1, \ldots, X_n$  sunt variabile aleatoare independente cu medie  $\mu$  și dispersie  $\sigma^2$  (nu neapărat normale), atunci pentru valori ale lui n ale volumului selecției suficient de mari, variabila aleatoare

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

este aproximativ o variabilă aleatoare normală standard.

Acest fapt permite ca formulele pentru intervalele de încredere pentru media  $\mu$  și dispersia  $\sigma^2$  a unei populații normale din secțiunile anterioare să poată fi folosite și în cazul altor distribuții, nu neapărat normale. Pentru ca aproximarea să fie bună, volumul n al selecției trebuie să fie cel puțin 20 în cazul intervalelor de încredere pentru medie, și cel puțin 50 în cazul intervalelor de încredere pentru dispersie.

#### Exerciții

Exercițiul 10.1 De ce sunt intervalele de încredere mai utile decât estimatorii punctuali?

Exercițiul 10.2 Ce se întâmplă cu intervalul de încredere din Examplul 10.2 dacă se folosește un nivel de încredere de 99% în loc de 95%? Dar dacă media de eșantionului este 8 în loc de 5?

Exercițiul 10.3 Să se determine un interval de 99% încredere pentru media  $\mu$  a unei populații normale cu abatere pătratică medie 2.5, folosind eșantionul

Exercițiul 10.4 Să se determine un interval de 95% încredere pentru media  $\mu$  a unei populații normale cu abatere pătratică medie 1.2, folosind eșantionul

Exercițiul 10.5 Să se determine un interval de 95% încredere pentru media  $\mu$  a unei populații normale cu dispersie  $\sigma^2 = 16$ , folosind un eșantion de volum 200 având medie 74.81.

Exercițiul 10.6 Ce se întâmplă cu intervalul de încredere din exercițiul anterior dacă volumul eșantionului se reduce la 50?

**Exercițiul 10.7** Ce volum al eșantionului este necesar pentru ca intervalul de 95% încredere pentru medie să aibă o lungimea  $2\sigma$ ?  $\sigma$ ?

Exercițiul 10.8 Să se determine un interval de 99% încredere pentru media unei populații normale cu dispersie  $\sigma^2 = 0.36$  folosind un eșantion de volum 290 cu medie 16.30.

Presupunând că populația din care următoarele eșantioane au fost extrase este normală, să se determine un interval de 99% încredere pentru media  $\mu$  a populației.

Exercițiul 10.9 Un eșantion de 20 de șuruburi cu medie 15.50 cm și dispersie 0.09 cm<sup>2</sup>.

Exercițiul 10.10 Temperatura de topire a aluminiului (în grade Celsius) în cazul eșantionului

Exercițiul 10.11 Conținutul de cupru (în procente) a unui aliaj de alamă în cazul eșantionului

**Exercițiul 10.12** Un interval de 99% încredere pentru parametrul p al distribuției binomiale folosind un eșantion de volum 24,000 cu frecvență relativă de apariție a succesului  $\frac{12,012}{24,000} = 0.5005$ .

Exercițiul 10.13 Să se determine un interval de 95% încredere pentru procentul de mașini aflate pe o autostradă care au frâne aflate în condiții necorespunzătoare, folosind folosind faptul că din 500 mașini verificate în mod aleator, 87 au avut frâne aflate în condiții necorespunzătoare.

Presupunând că populația din care următoarele eșantioane au fost extrase este normală, să se determine un interval de 95% încredere pentru dispersia  $\sigma^2$  a populației.

Exercitiul 10.14 Rezistența la rupere (kpsi) a unui aliaj de oțel aflat la temperatura camerei, folosind eșantionul

$$251, 255, 258, 253, 253, 252, 250, 252, 255, 256.$$

Exercițiul 10.15 Emisia de monoxid de carbon (grame pe km) a unui anumit tip de maşină (având viteză medie de 55 km/h), folosind eşantionul

$$17.3, 17.8, 18.0, 17.7, 18.2, 17.4, 17.6, 18.1$$

**Exercițiul 10.16** Dacă X este o variabilă aleatoare normală cu medie 40 și dispersie 4, ce fel de distribuție au variabilele aleatoare 3X și 5X - 2?

**Exercițiul 10.17** Dacă  $X_1$  şi  $X_2$  sunt variabile aleatoare normale independente, cu medii 16, respectiv 12, şi dispersii 8, respectiv 2, care este distribuția variabilei aleatoare  $4X_1 - X_2$ ?

**Exercițiul 10.18** O maşină umple cutii cântărind Y kg cu X kg de sare, unde X şi Y sunt variabile aleatoare nromale cu medii 200 kg, respectiv 10 kg, şi dispersii 2 kg, respectiv 0.5 kg. Ce procent de cutii rezultate vor cântări între 208 kg și 212 kg?

Exercițiul 10.19 Dacă greutatea X a sacilor de ciment este distribuită normal cu medie 40 kg și dispersie 2 kg, câți saci de ciment poate căra un camion dacă probabilitatea ca greutatea totală să depășească 2,000 kg este de 5%?